

Informe de verificación de la replicación R → Python

Proyecto 2: Perfil sociodemográfico de la paternidad: clasificación con regresión logística y regularización · **Autor:** Ricardo José Córdova Soriano · **Fecha:** 26/09/2026

Replicación exitosa: 37 de 37 comparaciones superadas (51,860 valores contrastados). El modelo seleccionado, las variables, los folds y todas las decisiones del análisis son idénticos en ambos lenguajes.

Metodología

Se ejecutaron de forma independiente el R Markdown (`R/02_Regresion_Logistica_DatosGSS.Rmd`) y el script de Python (`Python/02_Regresion_Logistica_DatosGSS.py`), y se contrastaron todos sus resultados: particiones, selección de variables, validación cruzada fold a fold, métricas en prueba, coeficientes, pruebas estadísticas, trayectorias de los modelos penalizados y la búsqueda de hiperparámetros.

Componentes replicados desde cero en Python

Varias funciones de R no tienen equivalente directo en Python. El módulo `Python/rcompat.py` las reimplementa y reproduce sus resultados:

- **Generador aleatorio de R** (`set.seed()` , Mersenne-Twister y muestreo por rechazo de `sample()`), incluido el muestreo con *hash* que R usa para poblaciones grandes.
- **Particiones de caret:** `createDataPartition()` , `createFolds()` y `createMultiFolds()` , además de la semilla interna que `train()` extrae antes de generar los folds.
- **step()** con criterios AIC y BIC en sus tres direcciones.
- **glmnet y cv.glmnet** : el mismo problema de optimización (elastic net logístico con estandarización interna), la misma secuencia de λ y reglas de parada de la trayectoria, y la interpolación de predicciones entre las secuencias de λ de cada fold (`lambda.interp`).

Equivalencias directas

- `glm(family = binomial)` → `statsmodels.formula.api.glm(family=Binomial())`.
- `car::Anova(type = "II")` → pruebas de razón de verosimilitudes por variable.
- `pROC::auc()` → AUC de Mann-Whitney con empates ponderados por $\frac{1}{2}$.
- `confint.default()` → intervalos de Wald con `scipy.stats.norm.ppf(0.975)`.

Resultados

Verificación de la replicación R → Python

Proyecto 2 · Regresión logística · 37 comparaciones · 51,860 valores

Métrica	Valores	Criterio	Máx. dif. absoluta	Máx. dif. relativa	Resultado
Datos					
Partición entrenamiento–prueba (índices)	1629	Idéntico	0	0	✓ Idéntico
Selección de variables					
Variables elegidas por los 6 métodos	6	Idéntico	—	—	✓ Idéntico
Número de parámetros	6	Idéntico	0	0	✓ Idéntico
AIC y BIC de los 6 modelos	12	Alta precisión	1.59×10^{-12}	1.13×10^{-15}	✓ Coincide
Validación cruzada					
Folds de caret (5 × 20, índices)	32580	Idéntico	0	0	✓ Idéntico
Etiquetas de remuestreo	900	Idéntico	—	—	✓ Idéntico
AUC, Kappa y accuracy por fold (3 modelos)	900	Alta precisión	5.55×10^{-16}	1.20×10^{-15}	✓ Coincide
Resumen (media, DE, mín., mediana, máx.)	45	Alta precisión	4.44×10^{-16}	2.22×10^{-15}	✓ Coincide
Evaluación en prueba					
Umbral de clasificación	1	Alta precisión	2.22×10^{-16}	3.08×10^{-16}	✓ Coincide
Matriz de confusión	4	Idéntico	0	0	✓ Idéntico
AUC, accuracy, Kappa, sensibilidad y especificidad (3 modelos)	15	Alta precisión	4.44×10^{-16}	6.35×10^{-16}	✓ Coincide
Modelo BIC					
Nombres de los coeficientes	9	Idéntico	—	—	✓ Idéntico
Coefficientes	9	Alta precisión	3.91×10^{-15}	2.11×10^{-13}	✓ Coincide
Errores estándar	9	Alta precisión	7.77×10^{-16}	4.13×10^{-15}	✓ Coincide
p-valores	9	Alta precisión	1.22×10^{-14}	9.76×10^{-14}	✓ Coincide
Intervalos de confianza de los odds ratios	18	Alta precisión	5.33×10^{-14}	5.75×10^{-15}	✓ Coincide

ANOVA tipo II (LR, gl, p)	15	Alta precisión	2.56×10^{-13}	1.17×10^{-13}	✓ Coincide
Regularización					
Columnas de la matriz de diseño	33	Idéntico	—	—	✓ Idéntico
LASSO: secuencia de λ	75	Alta precisión	1.80×10^{-15}	1.28×10^{-14}	✓ Coincide
LASSO: parámetros no nulos por λ	75	Idéntico	0	0	✓ Idéntico
LASSO: coeficientes e interceptos	2550	Precisión glmnet	2.66×10^{-6}	6.10×10^{-4}	✓ Coincide
Elastic Net ($\alpha = 0.1$): secuencia de λ	87	Alta precisión	1.82×10^{-14}	1.32×10^{-14}	✓ Coincide
Elastic Net ($\alpha = 0.1$): parámetros no nulos por λ	87	Idéntico	0	0	✓ Idéntico
Elastic Net ($\alpha = 0.1$): coeficientes e interceptos	2958	Precisión glmnet	1.71×10^{-6}	2.01×10^{-2}	✓ Coincide
Ridge: secuencia de λ	100	Alta precisión	9.52×10^{-13}	7.45×10^{-15}	✓ Coincide
Ridge: parámetros no nulos por λ	100	Idéntico	0	0	✓ Idéntico
Ridge: coeficientes e interceptos	3400	Precisión glmnet	1.22×10^{-7}	1.15×10^{-5}	✓ Coincide
Ajuste de hiperparámetros					
Asignación de folds (foldid)	1629	Idéntico	0	0	✓ Idéntico
LASSO: λ mínimo y λ 1-SE	2	Alta precisión	8.19×10^{-16}	1.02×10^{-14}	✓ Coincide
LASSO: AUC medio y error estándar por λ	150	Precisión glmnet	9.24×10^{-6}	2.54×10^{-5}	✓ Coincide
Rejilla $\alpha \times \lambda$: valores de α y λ	1760	Alta precisión	9.52×10^{-13}	1.40×10^{-14}	✓ Coincide
Rejilla $\alpha \times \lambda$: parámetros no nulos	880	Idéntico	0	0	✓ Idéntico
Rejilla $\alpha \times \lambda$: AUC medio y AUC – 1 EE	1760	Precisión glmnet	9.24×10^{-6}	1.13×10^{-5}	✓ Coincide
Umbral 1-SE	1	Precisión glmnet	1.11×10^{-16}	1.37×10^{-16}	✓ Coincide
Modelo regularizado					
α y λ seleccionados	2	Alta precisión	8.19×10^{-16}	8.47×10^{-15}	✓ Coincide
Coefficientes del modelo definitivo	34	Precisión glmnet	3.82×10^{-9}	2.45×10^{-8}	✓ Coincide
Métricas en prueba (logístico y regularizado)	10	Precisión glmnet	4.44×10^{-16}	5.53×10^{-16}	✓ Coincide
Idéntico: igualdad exacta. Alta precisión: $ \text{Python} - R \leq 1e-10 + 1e-9 \cdot R $. Precisión glmnet: $ \text{Python} - R \leq 1e-5 + 1e-4 \cdot R $.					
La tolerancia de los modelos penalizados refleja el criterio de convergencia iterativo de glmnet; la réplica en Python alcanza un valor de la función objetivo igual o menor que el de R en todos los casos.					